Universidad de Costa Rica
Curso: Herramientas de Datos I

Cosecha de cafe

Predicción de la Cosecha de Café en Costa Rica mediante Modelos Estadísticos en R

Estudiante a cargo
Jerald Valverde Mora
23 de noviembre de 2026

Introduccion

El cafe es uno de los productos agricolas mas importantes en la historia de Costa Rica, no solo por su impacto como producto, sino como componente primorial de la historia y uno de los motores economicos del pais a traves de los anos. Al ser un producto agricola, la cantidad que se produce de este esta sujeto a distintas variables que pueden cambiar a lo largo del tiempo; algunos de ellos son los factores climaticos, de mercado y la bienalidad de la planta. La produccion total ha seguido una tendencia a que las cosechas que se producen en cada temporada sean fluctuantes y tiendan a tener valores cada vez mas bajos, estando en 3.3 millones en 1994 y bajando a 1.8 millones de fanegas en 2025 (ICAFE, pag. 88, 2025).

La intencion de este proyecto es anticipar el volumen de cada cosecha para productores, exportadores y beneficiadores; asi como, interpretar el ejercicio habitual que realiza la OIC (Organizacion Internacional del Cafe), que estima la produccion de cafe. La propuesta es estimar la cosecha nacional 2026-2027 con tres modelos estadísticos en R, a partir de la producción y el precio del ICAFE, el clima de NASA POWER y un indicador del fenómeno ENOS de la NOAA.

Objetivo General

Desarrollar y comparar tres modelos en R (regresión lineal , regresión Ridge y árbol de regresión) que permitan estimar el volumen de la cosecha nacional de café de Costa Rica para el periodo 2026-2027, a partir de variables climáticas, de mercado y del comportamiento histórico de la producción.

Metodologia

Obtencion y tratamiento de los datos

La producción nacional de café y el precio de exportación provienen del Informe sobre la Actividad Cafetalera de Costa Rica del Instituto del Café de Costa Rica (ICAFE, 2025), entidad reguladora del sector según la Ley N.º 2762 de 1961, que reporta estas series por cosecha desde 1994-1995. El ICAFE expresa la producción en sacos de 46 kg, por lo que se convirtió a sacos de 60 kg, estándar internacional. Las tablas se extrajeron directamente del informe en PDF.

Los datos climáticos (precipitación (mm/dia) y temperatura medias (°C) de abril a octubre, ventana de floración y llenado del fruto según el ICAFE) se obtuvieron de NASA POWER (NASA, s. f.), que ofrece series satelitales con cobertura global desde 1981. Se utilizó un único punto en Pérez Zeledón, segunda región productora del país (aproximadamente 13 % de la producción nacional; ICAFE, 2025) y zona de origen del autor, por lo que el clima resultante es una aproximación

regional y no un promedio nacional. Como indicador del fenómeno de El Niño–Oscilación del Sur (ENOS) se utilizó el Índice Oceánico Relativo (RONI) de la NOAA (2026), con registros mensuales desde 1950, promediado en la misma ventana.

Construcción de variables

Cada cosecha se asocia a su ano de inicio: la cosecha 2023-2024 se asocia al año 2023, de esta manera; el clima y el RONI se usan del periodo de abril a octubre del ano respectivo a la recoleccion. Como variable respuesta se da la produccion nacional en sacos de 60kg, que se obtiene al multiplicar el cafe oro dado en sacos de 46kg por 46/60. Se descartan las exportaciones, el consumo nacional y el rendimiento como predictores ya que se calculan a partir de la misma cosecha que se pretende estimar. los datos climaticos (precipitacion y temperatura) se promedian sobre los meses mencionados de cada ano, asi como el RONI. Para tomar la bienalidad se incluye la produccion de la cosecha anterior como variable rezagada, igual manera el precio, ya que este se conoce una vez terminada la cosecha. Al tomar este rezago se pierde la primera cosecha, por lo que se contemplan $n = 30$ observaciones completas. los datos predictores se estandarizaron antes de ajustar la regresion de Ridge ya que es sensible a la escala. La cosecha 2026-2027 se proyecta con el clima y el RONI de 2026 y la producción y el precio de la cosecha 2025-2026.

Modelos

regresion lineal

modela la relación de dependencia entre una variable dependiente (lo que se desea predecir, Y) y una o más variables independientes (las predictoras, X) mediante una línea recta o superficie. Es el modelo base, interpretable y parsimonioso.

regresion ridge

Es una técnica de regresión estadística que se utiliza para corregir el sobreajuste y lidiar con la multicolinealidad (cuando las variables independientes están muy correlacionadas entre sí) (IBM, 2026). Se utiliza porque el rendimiento agricola depende de muchas variables que estan fuertemente conectadas entre si (multicolinealidad).

$$\mathrm{RSS}_{\mathrm{Ridge}} = \sum_{i=1}^{n}(y_i - \hat{y}_i)^2 + \lambda \sum_{j=1}^{p} \beta_j^2$$

Donde controla el nivel de penalizacion, se toma por validacion cruzada, y_i es la cosecha real observada, $\hat{y}_i$ es la cosecha predicha por el modelo. y p la cantidad de variables predictoras.

arbol de regresion

Divide las cosechas en grupos mediante reglas sucesivas sobre las variables y predice con el promedio de cada grupo (James et al., 2021)". Este se utiliza porque no asume la linealidad de las variables y las reglas que utiliza son faciles de interpretar. Es un poco inestable con pocos datos.

referencia ingenua

Como referencia se usa el método ingenuo (Hyndman y Athanasopoulos, 2021), que pronostica cada cosecha con el valor observado en la cosecha del periodo anterior: $\hat{y}_{t+1} = y_t$

Validación

El desempeño de los modelos se evalua mediante la tecnica del backtesting con ventana creciente, que utiliza los datos del pasado para medir su comportamiento. Se ajusta cada modelo con las cosechas hasta el año t y se predice la cosecha $t+1$, repitiendo el proceso desde las primeras 15 observaciones hasta la última cosecha disponible. Con las n predicciones resultantes se calculan la raíz del error cuadrático medio (RMSE), el error absoluto medio (MAE) y el coeficiente de determinación fuera de muestra (R^2):

$$RMSE = \sqrt{\frac{1}{n}\sum_{i=1}^{n}(y_i - \hat{y}_i)^2}, \quad MAE = \frac{1}{n}\sum_{i=1}^{n}|y_i - \hat{y}_i|, \quad R^2 = 1 - \frac{\sum_{i=1}^{n}(y_i - \hat{y}_i)^2}{\sum_{i=1}^{n}(y_i - \bar{y})^2}$$

donde $\bar{y}$ es la media de lo observado. El RMSE penaliza los errores grandes, el MAE indica el error promedio, ambos se expresan en sacos de 60 kg. El R^2 fuera de muestra puede tomar valores negativos cuando el modelo predice peor que la media. Como referencia se incluye el método ingenuo, que pronostica cada cosecha con la anterior (Hyndman y Athanasopoulos, 2021). Para proyectar la cosecha 2026-2027 se selecciona el modelo con menor RMSE.

Alcance y limitaciones

- La cosecha 2026-2027 no puede validarse contra un valor real, ya que aún no ha concluido.
- El clima proviene de un único punto en Pérez Zeledón, que representa cerca del 13 % de la producción nacional, por lo que es una aproximación regional y no un promedio del país.
- La precipitación, la temperatura y el RONI están correlacionados, porque el ENOS influye en el clima, lo que puede volver inestables los coeficientes de la regresión lineal.
- Se cuenta con unas 30 observaciones frente a cinco variables predictoras, lo que incrementa el riesgo de sobreajuste, especialmente en el árbol de regresión.

codigo extraccion de datos

Resultados

Análisis exploratorio

La producción nacional pasó de 2 498 409 sacos de 60 kg en la cosecha 1994-1995 a 1 170 000 en 2025-2026 (Figura 1). Los predictores se correlacionan mucho entre sí, en especial la producción anterior con el precio rezagado (r = -0.75) y con la lluvia (r = -0.69), lo que sugiere que comparten una tendencia en el tiempo (Figura 2).

Figura 1: Producción nacional de café por cosecha. Fuente: elaboración propia con datos del ICAFE (2025) y La República (2026).

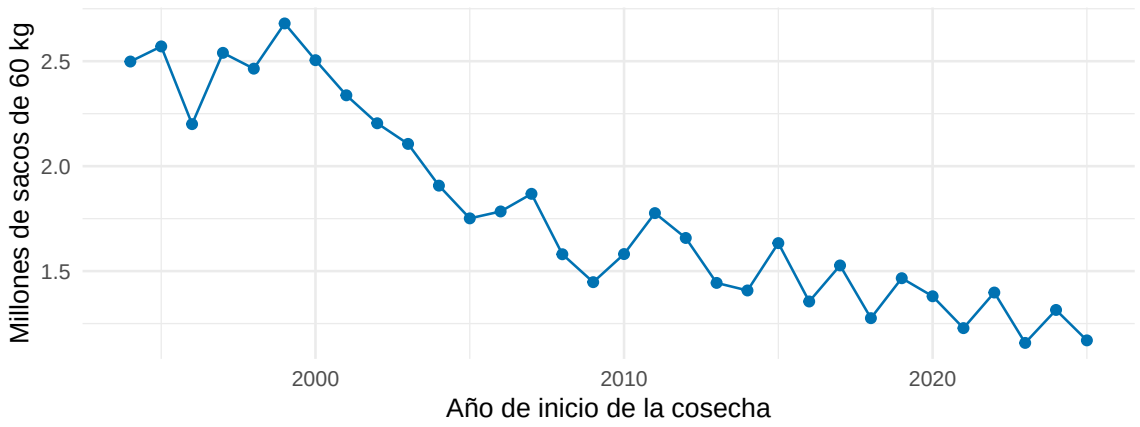
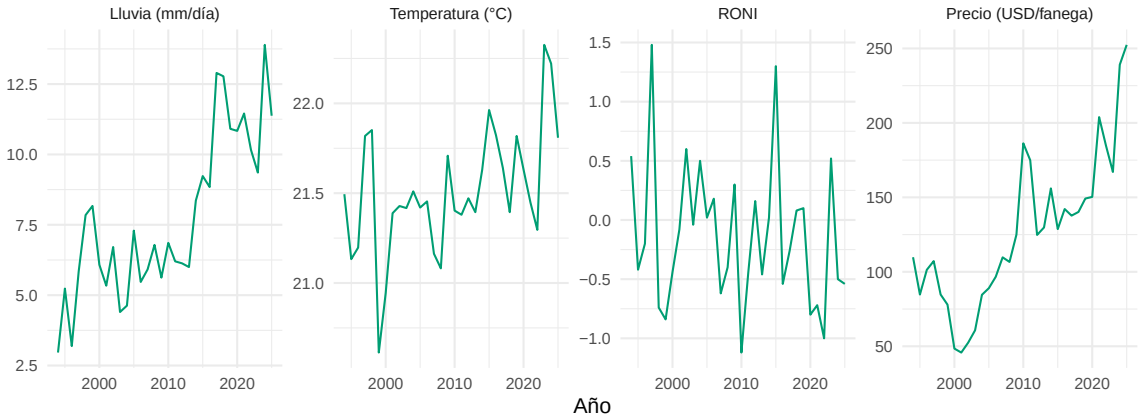


Figura 2: Evolución de los predictores. Fuente: elaboración propia con datos de NASA POWER, NOAA y el ICAFE (2025).



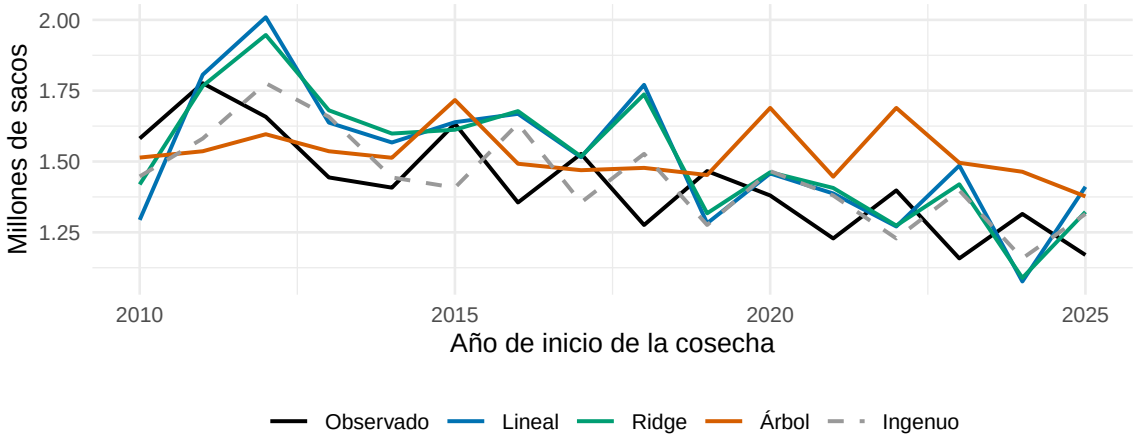
Resultados de los modelos

Tabla 1 resume el backtesting. El método ingenuo obtuvo el menor error (RMSE de 183 150 sacos), seguido del árbol (187 465), Ridge (214 832) y el modelo lineal (239 313), y los cuatro tuvieron un R^2 fuera de muestra negativo. El modelo lineal explicó 0.85 de la variabilidad dentro de la muestra, pero su R^2 fuera de ella fue de -0.93, señal de sobreajuste. Completar: sesgo de los modelos en 3

Tabla 1: Error de predicción en el backtesting (sacos de 60 kg). Fuente: elaboración propia.

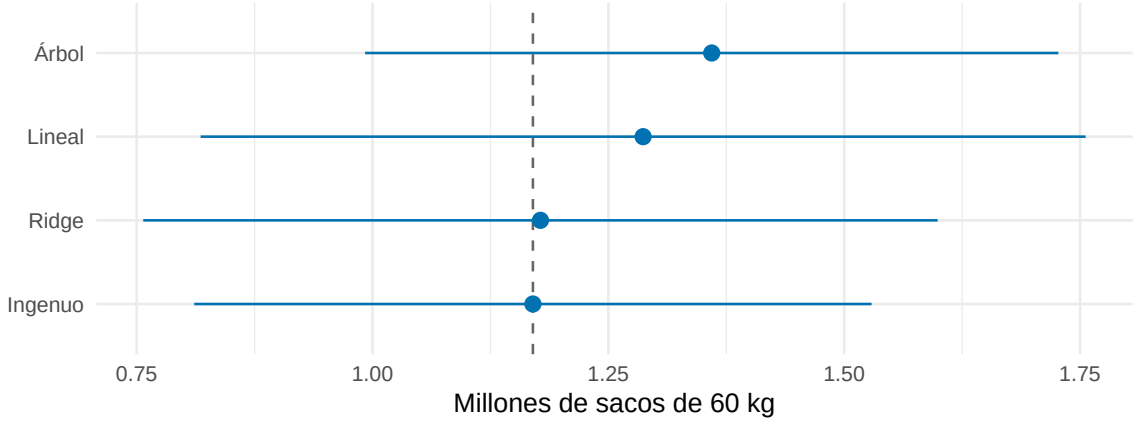
Modelo	RMSE	MAE	R^2 fuera de muestra
Ingenuo	183 150	172 750	-0.13
Árbol	187 465	160 763	-0.18
Ridge	214 832	179 751	-0.55
Lineal	239 313	200 116	-0.93

Figura 3: Producción observada y predicha en el backtesting (sacos de 60 kg). Fuente: elaboración propia con datos del ICAFE (2025).



Para 2026-2027 los modelos proyectan entre 1 170 000 y 1 359 560 sacos de 60 kg (Figura 4). El árbol, el de menor error entre los tres modelos, proyecta 1 359 560 sacos, un 16.2 % más que la cosecha 2025-2026. Los rangos son amplios porque el error del backtesting es grande respecto a las diferencias entre modelos.

Figura 4: Proyección de la cosecha 2026-2027 por modelo, con rango aproximado de ±1.96 RMSE. Fuente: elaboración propia.



Conclusiones

1. [Con estos datos ningún modelo mejora de forma clara al método ingenuo; la cosecha anterior concentra casi toda la información predictiva.]
2. [La proyección para 2026-2027 está entre 1 170 000 y 1 359 560 sacos de 60 kg, con una incertidumbre amplia.]
3. [Con 31 cosechas y predictores que comparten tendencia, no es posible separar el efecto del clima, el RONI y el precio.]

Bibliografia

Instituto del Café de Costa Rica. (2025). Informe de la actividad cafetalera de Costa Rica 2025. https://www.icafe.cr/wp-content/uploads/informacion_mercado/informes_actividad/actual/Informe%20Actividad%20Cafetalera.pdf

Instituto Meteorológico Nacional. (s. f.). Avisos meteorológicos y atlas climatológico. Recuperado el 10 de noviembre de 2026, de https://www.imn.ac.cr

Instituto Meteorológico Nacional. (s. f.). Pronóstico climático. Recuperado el 10 de noviembre de 2026, de https://www.imn.ac.cr/web/imn/pronostico-climatico

National Aeronautics and Space Administration, Langley Research Center. (s. f.). Monthly and annual API documentation. NASA POWER. Recuperado el 10 de noviembre de 2026, de https://power.larc.nasa.gov/docs/services/api/temporal/monthly/

National Oceanic and Atmospheric Administration, Climate Prediction Center. (s. f.). Relative Oceanic Niño Index (RONI). Recuperado el 10 de noviembre de 2026, de https://www.cpc.ncep.noaa.gov/products/analysis_monitoring/enso/roni/

Ramírez. (s. f.). Actualización del área cafetalera nacional. Caficultura desde Costa Rica. https://ramirezcaficulturadesdecostarica.com/ct-191

James, G., Witten, D., Hastie, T., & Tibshirani, R. (2021). An Introduction to Statistical Learning: with Applications in R (2.ª ed.). Springer

IBM. (16 de agostp, 2026). ¿Qué es regression?. https://www.ibm.com/mx-es/think/topics/ridge-regression Cita el libro en APA 7: Hyndman, R. J., y Athanasopoulos, G. (2021). Forecasting: Principles and practice (3.ª ed.). OTexts. [https://otexts.com/fpp3/]

Anexos

cargar librerias:

codigo de los modelos